

Локальные модели на обычном ПК

Диалоговые боты и голосовые помощники



Проверить, идет ли запись

Меня хорошо видно & слышно?





Третьякова Анастасия

ML-engineer в "Банк ДОМ.РФ"

- Более 2 лет коммерческой разработки в стартапе на позиции ML-engineer
- 4 года объясняю программирование детям и взрослым

 @teamurao

 tretyakova.nastya@inbox.ru

Карта курса



СТАРТ

Основы и базовая архитектура

Создание Telegram-бота на aiogram

Работа с базами данных

RAG: поиск по документам и ссылки на источники

ВКонтакте-боты

LLM: подключение и основы промптинга

Webhook, Docker, «около-прод»

Голосовые ассистенты: распознавание речи, обработка и озвучка

ИИ-агенты (LangChain/LangGraph)

Интеграции, управление и мультиканальность

ФИНИШ



Проектная работа

Тесты, мониторинг и деплой

Маршрут вебинара

Железо VS. Локальные модели

Ollama: установка и первый запуск

Работа с локальными моделями

Работа с облачными моделями
ollama

Ollama: cloud vs. local модели



Цели вебинара

К концу занятия вы сможете

1. Научитесь устанавливать и запускать локальную LLM;
2. Научитесь сравнивать качество и скорость с облачными решениями



Железо

VS.

Локальные модели

На какие параметры железа ориентироваться при выборе модели?

1. **VRAM** (память видеокарты) — главное для скорости и размеров моделей.

Примерно: 4–6 GB → 1–3B; 8–12 GB → 7–13B; 16–24 GB → 13–34B (в зависимости от квантования).
2. **RAM** (оперативная память) важна, если модель частично/полностью в CPU.
3. **CPU** (число ядер и AVX/AVX2) влияет на скорость, особенно без GPU.
4. **Диск** – модели занимают много места (гигабайты), плюс кеш.



Установка Ollama

<https://ollama.com/>



[Models](#) [GitHub](#) [Discord](#) [Docs](#) [Pricing](#)

🔍 Search models



What will you build?

Ollama is the easiest way to automate your work using open models, while keeping your data safe.

Download



Ollama works with your favorite tools

Coding

Codex

Claude Code

OpenCode

Documents & RAG

LangChain

LlamaIndex

AnythingLLM

Automation

n8n

Dify

OpenClaw

Chat

Open WebUI

Onyx

Msty

[View all →](#)





LIVE



Ключевые тезисы занятия

1. Локальная LLM - это трата собственных ресурсов: она медленная, ограниченная и требует осознанного управления (таймауты, лимиты).
2. Облако и локальные модели решают разные задачи: облако - про качество и скорость, локальное расположение - про контроль, приватность и предсказуемость.
3. В зависимости от требований безопасников/бизнеса/ресурсов выбираем расположение (облако/локально), далее выбираем модель, ориентируясь на параметры и решаемые задачи.



Заполните, пожалуйста, опрос о занятии

Мы читаем все ваши сообщения
и берем их в работу 🖋️❤️

OTUS

